

Hallucinations émotionnelles dans l'interaction humain-IA

Vers un cadre théorique pour analyser la projection anthropomorphique sur les modèles de langage conversationnels

Nicolas Grangeret
Université Paris 3 Sorbonne Nouvelle
nicolas.grangeret@sorbonne-nouvelle.fr

Working paper - Version 1.0 - Mars 2026
Bibliographie en cours de consolidation - version enrichie à paraître

Résumé

Cet article introduit le concept d'hallucination émotionnelle, désignant le processus par lequel un utilisateur projette sur un modèle de langage de grande taille des attributs intentionnels - conscience, sincérité, empathie - en réponse à des productions de nature purement statistique, générant une réaction affective ou décisionnelle disproportionnée. Distinct des hallucinations factuelles documentées dans la littérature technique, ce phénomène est analysé à travers un cadre théorique intégratif articulant trois mécanismes convergents : l'anthropomorphisme computationnel, la défaillance de vigilance épistémique et la vulnérabilité situationnelle. Une étude empirique en cours auprès d'étudiants en formation initiale et continue vise à tester les hypothèses dérivées de ce cadre, au moyen d'un questionnaire en cinq dimensions et de deux vignettes situationnelles. Un dispositif pédagogique en cinq axes est proposé comme réponse implémentable dans des contextes de formation variés. Les enjeux soulevés dépassent le cadre académique et interrogent plus largement les conditions d'une autonomie cognitive collective à l'ère des intelligences artificielles conversationnelles.

Mots-clés : *hallucination émotionnelle, anthropomorphisme, vigilance épistémique, modèles de langage, autonomie cognitive, éducation critique*

1. Introduction et problématique

1.1 Contexte : l'irruption des LLM dans les pratiques quotidiennes

Depuis le déploiement public de ChatGPT en novembre 2022, les modèles de langage de grande taille (Large Language Models, LLM) ont connu une diffusion sans précédent dans les pratiques numériques ordinaires. En l'espace de deux ans, ces systèmes sont passés du statut d'outils réservés à des communautés techniques restreintes à celui d'interfaces conversationnelles accessibles à tout utilisateur disposant d'une connexion internet. ChatGPT, Claude, Gemini, Mistral ou encore Deepseek comptent aujourd'hui plusieurs centaines de millions d'utilisateurs actifs à travers le monde, dans des contextes aussi variés que la rédaction professionnelle, la recherche documentaire, l'aide à la décision ou le soutien dans des moments de doute personnel.

Ce que cette diffusion massive révèle, au-delà des usages instrumentaux, c'est une transformation plus profonde des rapports cognitifs et affectifs que les individus entretiennent avec les systèmes numériques. La sophistication croissante du langage produit par les LLM - sa fluidité, sa cohérence interne, sa capacité à s'adapter au registre de l'interlocuteur - crée les conditions d'une expérience conversationnelle qui déborde le simple échange d'informations. Les utilisateurs ne consultent plus seulement un outil : ils parlent à quelque chose qui leur répond, les rassure, valide leurs intuitions ou formule avec précision ce qu'ils ressentaient confusément.

C'est précisément cet écart entre la nature réelle de ces systèmes - des modèles probabilistes produisant des séquences de tokens statistiquement cohérentes - et l'expérience subjective que leur usage génère qui constitue l'objet du présent travail.

1.2 Une lacune dans la littérature

La recherche sur les hallucinations des LLM s'est jusqu'ici principalement concentrée sur leurs défaillances factuelles : la production d'informations incorrectes présentées avec une assurance trompeuse (Bender et al., 2021). Cette acception technique du terme, bien documentée, ne rend toutefois compte que d'une partie du phénomène. Elle situe le problème du côté du système et laisse dans l'ombre une dimension tout aussi saillante : ce que l'utilisateur projette sur le système.

Par ailleurs, si la littérature consacrée à l'anthropomorphisme des agents conversationnels est substantielle (Epley, Waytz & Cacioppo, 2007 ; Nass & Moon, 2000), elle porte pour l'essentiel sur des chatbots à vocation relationnelle explicite - Replika, Woebot, ou les assistants vocaux domestiques - dont la conception même invite à une interaction para-sociale. Les LLM généralistes, conçus comme outils polyvalents et non comme compagnons numériques, ont jusqu'ici été peu étudiés sous l'angle des projections émotionnelles qu'ils suscitent chez leurs utilisateurs.

Enfin, la littérature francophone demeure quasi absente sur cette articulation spécifique entre émotions, raisonnement et délégation décisionnelle dans l'usage des LLM en contexte éducatif. L'originalité du présent travail réside précisément dans ce croisement : une population estudiantine, un outil généraliste, et un

cadre théorique mobilisant conjointement la psychologie cognitive, les sciences de l'information et de la communication, et les sciences de l'éducation.

1.3 Objectifs du working paper

Ce document poursuit quatre objectifs complémentaires. Il propose d'abord une définition opérationnelle du concept d'hallucination émotionnelle, terme inédit dans la littérature académique, désignant non une défaillance du système mais une projection de l'utilisateur. Il construit ensuite un cadre théorique intégratif articulant trois mécanismes convergents : l'anthropomorphisme computationnel, la défaillance de vigilance épistémique et la vulnérabilité situationnelle. Il présente par ailleurs la méthodologie d'une étude empirique en cours auprès d'étudiants en formation initiale et continue, dont les résultats viendront ultérieurement alimenter ou invalider les hypothèses formulées. Il propose enfin un dispositif pédagogique en cinq axes, conçu comme réponse applicable dans des contextes de formation variés.

1.4 Problématique centrale

Ces quatre objectifs convergent vers une question centrale :

Dans quelle mesure les modèles de langage conversationnels généralistes induisent-ils, chez leurs utilisateurs - notamment étudiants -, des projections émotionnelles et des délégations décisionnelles susceptibles d'altérer leur autonomie cognitive et leur vigilance épistémique ? Et quelles interventions pédagogiques permettent d'y remédier ?

Cette formulation articule intentionnellement deux dimensions - descriptive et prescriptive - afin de maintenir la cohérence entre le volet théorique, le volet empirique et le volet applicatif du présent travail.

2. Définition et conceptualisation

2.1 Les hallucinations dans la littérature IA : un concept à double sens

Le terme « hallucination » appliqué aux systèmes d'intelligence artificielle désigne, dans son acception technique dominante, la tendance des LLM à produire des affirmations factuellement incorrectes ou invérifiables, présentées avec une assurance stylistique qui ne reflète aucunement leur fiabilité réelle (Bender et al., 2021). Ce phénomène, largement documenté depuis les premières évaluations publiques des modèles GPT, BERT et de leurs successeurs, est devenu l'un des axes centraux de la recherche en traitement automatique du langage.

Il convient de noter que l'usage du terme « hallucination » dans ce contexte technique a suscité des débats au sein de la communauté scientifique. Cardon, Cointet et Mazières (2018) ont montré plus largement que le lexique de l'IA - « intelligence », « apprentissage », « compréhension » - tend à façonner des représentations des systèmes qui débordent leur réalité technique. Cette observation vaut pour le terme « hallucination » lui-même, dont l'usage dans le

champ de l'IA constitue cependant une métaphore opératoire désormais stabilisée dans la littérature, et que nous ne discutons pas ici pour elle-même.

C'est en partant de cette acception technique stabilisée que le présent travail propose un déplacement conceptuel : non plus la défaillance du système, mais la projection de l'utilisateur. Le terme « hallucination » retrouve ici sa pleine pertinence dans son sens premier - une perception déformée de la réalité par un sujet humain - ce qui fonde la symétrie proposée entre les deux acceptions.

	Hallucination factuelle	Hallucination émotionnelle
Sujet	Le système IA	L'utilisateur humain
Nature	Erreur de production	Projection cognitive
Mécanisme	Probabilité statistique mal calibrée	Anthropomorphisme et vulnérabilité
Conséquence	Information fausse	Dépendance ou délégation
Correctif	Amélioration technique	Intervention pédagogique

Tableau 1. Hallucination factuelle et hallucination émotionnelle : comparaison des deux acceptions.

2.2 Définition proposée : l'hallucination émotionnelle

On propose de désigner par hallucination émotionnelle le processus par lequel un utilisateur projette sur un LLM des attributs intentionnels - conscience, sincérité, empathie, bienveillance - en réponse à des productions linguistiques de nature purement statistique, générant ainsi une réaction affective et/ou décisionnelle disproportionnée par rapport à la nature réelle du système.

Cette définition appelle plusieurs précisions. En premier lieu, la projection en question n'est pas nécessairement consciente ni délibérée. Il ne s'agit pas ici du jeu de rôle assumé que pratiquent certains utilisateurs avertis, qui savent parfaitement interagir avec un LLM sur un mode fictif tout en maintenant une distance critique. L'hallucination émotionnelle au sens retenu ici désigne au contraire une réaction spontanée, non contrôlée, qui persiste y compris chez des individus qui affirment par ailleurs savoir que l'IA ne ressent rien - révélant ainsi une dissonance mesurable entre conscience théorique et réaction affective spontanée.

En second lieu, le recours au terme « hallucination » est pleinement revendiqué. Il s'agit bien, dans les deux cas - factuel et émotionnel - d'une perception déformée de la réalité : dans un cas, l'utilisateur croit à une information que le système a fabriquée ; dans l'autre, il croit à une intentionnalité que le système ne possède pas. La symétrie est conceptuellement fondée.

2.3 Deux manifestations distinctes

L'hallucination émotionnelle se manifeste selon deux modalités distinctes, qui peuvent se combiner mais méritent d'être distinguées analytiquement.

La première, que l'on désigne par mirage de la validation, relève de l'axe affectif. L'utilisateur perçoit l'approbation ou le réconfort produits par le LLM comme un soutien émotionnel authentique, susceptible de répondre à un besoin psychologique réel. Il développe progressivement une forme de dépendance relationnelle asymétrique : asymétrique parce que la relation n'existe que d'un côté, le système n'ayant aucune représentation de l'utilisateur entre deux sessions, aucune mémoire affective, aucun investissement dans l'échange. Turkle (2011) avait anticipé ce type de dynamique à propos des robots de compagnie ; les LLM généralistes en constituent aujourd'hui une déclinaison plus diffuse et plus massive, d'autant plus insidieuse qu'ils ne sont pas conçus à cette fin.

La seconde manifestation, désignée par arbitraire statistique, relève de l'axe décisionnel. L'utilisateur délègue à un système probabiliste un jugement d'ordre moral, éthique ou critique, acceptant sa réponse comme une forme d'autorité. Ce faisant, il substitue à un raisonnement dialectique personnel une séquence de tokens sélectionnée selon des critères de vraisemblance linguistique - sans fondement éthique, sans ancrage dans une expérience vécue, sans responsabilité assumée. Bender et al. (2021) qualifient les LLM de stochastic parrots précisément pour souligner cette absence de substrat sémantique réel derrière la cohérence apparente des productions.

3. Cadre théorique

3.1 Premier mécanisme : l'anthropomorphisme computationnel

L'anthropomorphisme - tendance à attribuer des caractéristiques humaines à des entités non humaines - est un phénomène cognitif bien documenté, dont la théorie des trois facteurs proposée par Epley, Waytz et Cacioppo (2007) constitue le cadre de référence le plus cité dans la littérature. Selon ces auteurs, l'anthropomorphisme résulte de la convergence de trois facteurs indépendants mais cumulatifs.

Le premier est l'accessibilité des agents : la facilité avec laquelle des schémas cognitifs sociaux - ceux que nous activons spontanément pour interpréter le comportement d'autrui - sont disponibles et mobilisables face à une entité donnée. Plus une entité produit des signaux qui ressemblent à des comportements intentionnels, plus ces schémas s'activent automatiquement. Les LLM, en produisant un discours fluide, cohérent, adapté au registre de l'interlocuteur et apparemment empathique, constituent des déclencheurs particulièrement puissants de cette activation.

Le deuxième facteur est la motivation d'effectance : le besoin fondamental de prédire et de contrôler son environnement. Face à un système dont le fonctionnement interne demeure opaque pour la grande majorité des utilisateurs, attribuer des intentions au LLM constitue une stratégie cognitive économique - elle rend le comportement du système prévisible sans en comprendre les

mécanismes réels. Ce faisant, elle installe précisément la confusion que l'on cherche ici à analyser.

Le troisième facteur est le désir de connexion sociale : le besoin d'appartenance et de relation interpersonnelle. Epley et al. montrent que ce facteur est particulièrement actif dans les contextes d'isolement ou de solitude, ce qui rejoint directement les observations de Turkle (2011) sur la substitution technologique du lien humain et les données empiriques de Skjuve et al. (2021) sur les utilisateurs de chatbots compagnons.

Appliqué aux LLM, ce cadre permet de comprendre pourquoi l'anthropomorphisme computationnel n'est pas une erreur de raisonnement que commettraient seulement des utilisateurs naïfs ou peu instruits. Il s'agit d'une réaction cognitive largement automatique, activée par des caractéristiques intrinsèques des productions des LLM, et amplifiée par des contextes situationnels spécifiques. Cardon, Cointet et Mazières (2018) ajoutent à cette analyse une dimension sociolinguistique : le lexique même qui structure le discours public sur l'IA - « intelligence », « apprentissage », « compréhension », « raisonnement » - prépare cognitivement les utilisateurs à projeter des capacités mentales sur des systèmes qui n'en possèdent pas, bien avant même toute interaction directe.

3.2 Deuxième mécanisme : la défaillance de vigilance épistémique

La théorie de la vigilance épistémique, développée par Mercier et Sperber (2011, 2017), postule que les êtres humains sont dotés d'un mécanisme évolutif de filtrage des informations reçues d'autrui. Contrairement à une vision naïve de la communication humaine - selon laquelle nous accepterions par défaut les informations qui nous sont transmises - Mercier et Sperber montrent que nous évaluons en permanence, souvent de façon non consciente, la fiabilité de nos interlocuteurs et la plausibilité de leurs affirmations. Cette vigilance s'appuie sur des indices multiples : la cohérence interne du discours, la réputation de la source, la détection de signaux de non-sincérité, l'évaluation des intérêts potentiels de l'émetteur.

Or les LLM neutralisent précisément l'ensemble de ces indices. Ils ne présentent aucun des signaux habituels de non-fiabilité - pas d'hésitation, pas d'incohérence stylistique, pas de marqueurs d'incertitude non maîtrisée, pas d'intérêts visibles. Leur discours est invariablement structuré, assuré et bienveillant, quelle que soit la qualité réelle de l'information produite. La vigilance épistémique, calibrée pour fonctionner dans des contextes d'interaction humaine, se trouve ainsi désarmée face à un interlocuteur artificiel qui en imite les formes sans en partager les contraintes.

Un second facteur aggrave cette défaillance : l'effet de l'assiduité interactionnelle. Plus un utilisateur interagit fréquemment avec un LLM donné, plus il développe une familiarité qui érode la vigilance. Des travaux récents en psychologie cognitive des LLM (Jakesch et al., 2023) montrent que les utilisateurs réguliers peinent davantage à identifier les productions d'IA que les utilisateurs occasionnels, suggérant que l'exposition prolongée renforce précisément les mécanismes d'acceptation non critique au détriment du filtrage épistémique. Ce résultat contre-intuitif - plus on connaît, moins on se méfie - constitue l'un des enjeux pédagogiques majeurs identifiés dans le présent travail.

3.3 Troisième mécanisme : la vulnérabilité situationnelle

Les deux mécanismes précédents - anthropomorphisme et défaillance de vigilance épistémique - constituent des tendances cognitives générales, présentes à des degrés divers chez la quasi-totalité des utilisateurs. Le troisième mécanisme n'est pas une disposition permanente mais un modérateur situationnel : il amplifie les deux premiers dans des contextes spécifiques de fragilité psychologique ou de surcharge cognitive.

Turkle (2011) a montré, à partir de recherches ethnographiques sur l'usage des robots de compagnie et des interfaces numériques, que les individus se tournent vers les technologies relationnelles de substitution précisément dans les moments où le lien humain est perçu comme insuffisant, indisponible ou trop coûteux émotionnellement. Cette dynamique de substitution n'implique pas nécessairement un isolement chronique : elle peut s'activer dans des situations transitoires de stress intense, de fatigue décisionnelle ou d'incertitude sur soi.

Skjuve et al. (2021), dans leur étude empirique sur les relations humain-chatbot, confirment et précisent ce résultat : les utilisateurs qui développent les formes d'attachement les plus marquées envers les chatbots conversationnels sont significativement plus susceptibles de présenter des niveaux élevés d'anxiété sociale et de solitude perçue. La corrélation n'implique pas de causalité univoque - il peut s'agir d'une sélection des usages autant que d'un effet des usages - mais elle indique clairement que la vulnérabilité situationnelle constitue un terrain favorable à l'hallucination émotionnelle.

En contexte académique, cette vulnérabilité prend des formes identifiables : périodes d'examens, charge cognitive élevée, incertitude sur les choix d'orientation, sentiment d'incompréhension par l'environnement institutionnel. La disponibilité permanente des LLM - contrairement aux enseignants, aux pairs ou aux conseillers d'orientation, dont l'accès est limité dans le temps - les rend particulièrement attractifs dans ces moments précisément où la vigilance épistémique est la plus abaissée.

3.4 Convergence des trois mécanismes : vers un modèle intégratif

Les trois mécanismes décrits ne sont pas indépendants : ils se renforcent mutuellement selon une dynamique cumulative. L'anthropomorphisme computationnel abaisse le seuil d'activation de la réponse affective ; la défaillance de vigilance épistémique supprime les freins cognitifs qui pourraient tempérer cette réponse ; la vulnérabilité situationnelle amplifie les deux premiers en augmentant à la fois le besoin de réconfort et la disponibilité à déléguer le jugement.

La résultante de cette convergence est ce que l'on nomme hallucination émotionnelle, laquelle se manifeste sous l'une ou l'autre de ses deux formes - mirage de la validation ou arbitraire statistique - ou sous les deux simultanément selon les profils d'utilisateurs et les contextes d'usage.

Ce modèle intégratif présente une propriété essentielle pour la recherche : il est falsifiable. Chacune de ses composantes est mesurable indépendamment - l'anthropomorphisme par des items Likert inspirés d'Epley et al. (2007), la vigilance épistémique par des items adaptés de Mercier et Sperber (2017), la vulnérabilité situationnelle par des indicateurs d'anxiété et de solitude perçue. La

convergence des trois peut être testée empiriquement, et l'existence même de la dissonance conscience/réaction - savoir que l'IA ne ressent rien tout en réagissant affectivement à ses productions - constitue la variable centrale que l'étude en cours s'emploie à mesurer.

4. Présentation de l'étude empirique en cours

4.1 Objectifs et hypothèses de recherche

L'étude empirique présentée ici est en cours de réalisation au moment de la rédaction de ce working paper (février 2026). Elle vise à tester les hypothèses dérivées du cadre théorique exposé en Section 3, en mesurant empiriquement les dimensions constitutives de l'hallucination émotionnelle auprès d'une population d'étudiants en formation initiale et continue.

L'hypothèse principale est la suivante : les utilisateurs réguliers de LLM généralistes présentent des niveaux significativement plus élevés d'anthropomorphisme et de délégation décisionnelle que les utilisateurs occasionnels, y compris parmi les répondants déclarant un niveau de connaissance technique élevé. Cette formulation est délibérément contre-intuitive : elle postule que savoir ne protège pas, ou du moins ne protège pas suffisamment - que la conscience théorique du caractère artificiel des LLM ne constitue pas un rempart contre la réaction affective spontanée qu'ils suscitent.

Trois hypothèses secondaires complètent ce dispositif. La première (H1) postule que le niveau d'anxiété situationnelle modère positivement l'intensité de la projection émotionnelle : plus un répondant présente un niveau d'anxiété élevé au moment de l'enquête, plus ses scores sur les dimensions affectives devraient être élevés. La deuxième (H2) postule l'existence d'une dissonance mesurable entre conscience explicite et réaction affective spontanée : les répondants qui affirment savoir que l'IA ne ressent rien devraient néanmoins présenter des scores significatifs sur les items mesurant la projection émotionnelle. La troisième (H3) postule que les étudiants en management et marketing présentent des profils d'anthropomorphisme différenciés selon leur exposition préalable aux outils IA, reflet d'une tension entre usage instrumental intensif et absence de formation critique.

4.2 Population et terrain

La population cible est constituée d'étudiants en licence et en master, principalement dans les filières business, marketing et communication. Ce choix est motivé par trois considérations. Ces filières présentent d'abord une forte exposition aux LLM, les étudiants étant amenés à les utiliser aussi bien pour des travaux académiques que dans des perspectives professionnelles. Elles offrent ensuite une diversité de profils - niveaux d'études, parcours antérieurs, rapports à la technologie - favorable à l'identification de sous-groupes contrastés. Elles constituent enfin le terrain d'enseignement direct du chercheur, ce qui facilite l'accès au terrain et garantit la cohérence entre le questionnaire et les contextes d'usage effectivement observés.

Le recueil de données s'effectue auprès d'étudiants de l'IUT de Brest (licence professionnelle) et de l'organisme de formation Skilzh, avec un objectif de 150 répondants minimum, seuil jugé nécessaire pour la robustesse des analyses statistiques envisagées. La collecte est en cours au moment de la rédaction du présent document.

4.3 Instrument de mesure

L'instrument de collecte est un questionnaire de 43 questions structuré en neuf sections, déployé sur la plateforme Framiforms. Ce choix technique est motivé par des considérations éthiques : Framiforms est hébergé en France, conforme au RGPD, et ne commercialise pas les données collectées et permet de garantir l'anonymat - conditions essentielles pour une recherche portant sur des comportements émotionnels potentiellement sensibles.

Le questionnaire mobilise cinq dimensions principales correspondant aux composantes du cadre théorique : anthropomorphisme (questions 5 à 11), dépendance émotionnelle (questions 12 à 18), délégation décisionnelle morale (questions 19 à 24), vulnérabilité situationnelle (questions 25 à 28) et vigilance épistémique (questions 29 à 35). Les items Likert utilisent une échelle en cinq points, de 0 (pas du tout d'accord) à 4 (tout à fait d'accord) pour les dimensions attitudinales, et de 0 (jamais) à 4 (très souvent) pour les dimensions comportementales. Le questionnaire inclut également deux questions ouvertes destinées à recueillir des verbatims illustratifs, ainsi que des données sociodémographiques permettant les analyses de sous-groupes.

Il convient de signaler ici une limite instrumentale relative à H2 : la mesure de la dissonance conscience/réaction repose sur un nombre restreint d'items - principalement Q29 pour la dimension conscience et les items Q5 à Q10 pour la dimension réaction affective. Cet indice de dissonance, bien que fonctionnel, n'a pas la robustesse d'une échelle validée psychométriquement. Cette contrainte est assumée dans le cadre d'une étude exploratoire et sera traitée comme telle dans l'interprétation des résultats.

4.4 Les vignettes situationnelles

Deux vignettes situationnelles complètent le dispositif quantitatif. Elles présentent des scénarios concrets dans lesquels un étudiant fictif interagit avec un LLM, et demandent au répondant d'indiquer sa réaction spontanée parmi plusieurs modalités proposées.

La première vignette - Réconfort émotionnel - met en scène un étudiant traversant une période difficile et recevant une réponse empathique de la part de l'IA. Elle vise à mesurer la dissonance entre conscience théorique et réaction affective : un répondant peut simultanément savoir que la réponse est une production statistique et se sentir réellement réconforté par elle. La seconde vignette - Validation morale - présente un étudiant sollicitant le jugement de l'IA sur une décision éthiquement complexe et recevant une validation de sa position. Elle mesure la propension à la délégation décisionnelle et l'acceptation de l'autorité algorithmique.

4.5 Analyses prévues

Les données feront l'objet d'analyses en plusieurs étapes. Les statistiques descriptives permettront de caractériser les distributions sur chacune des cinq dimensions. Des analyses corrélationnelles entre dimensions testeront les relations postulées par le modèle intégratif, notamment la co-occurrence des trois mécanismes. Des comparaisons de groupes - utilisateurs réguliers contre occasionnels, niveaux d'anxiété contrastés - permettront de tester les hypothèses H1 et H3. Une analyse de régression multiple permettra de tester l'effet propre de la fréquence d'usage sur les scores d'anthropomorphisme et de délégation, en contrôlant le niveau de connaissance technique déclarée (Q42), afin de tester la robustesse de l'hypothèse principale. Une analyse factorielle exploratoire viendra vérifier la structure dimensionnelle du questionnaire. Enfin, une analyse thématique des verbatims recueillis via les questions ouvertes permettra d'enrichir et de nuancer les résultats quantitatifs par des données qualitatives.

5. Dispositif pédagogique en cinq axes

5.1 Principes fondateurs

Les recherches sur le changement de comportement cognitif montrent de façon convergente que la simple transmission d'information ne suffit pas à modifier des réactions automatiques profondément ancrées. Dire à un étudiant que l'IA ne ressent rien ne le protège pas de la projection émotionnelle - la dissonance conscience/réaction postulée par H2 en est précisément l'illustration. Toute intervention pédagogique visant à réduire l'hallucination émotionnelle doit donc cibler simultanément la dimension cognitive et la dimension affective, en travaillant aussi bien la représentation intellectuelle des LLM que la métacognition émotionnelle de l'utilisateur face à ses propres réactions.

Le dispositif proposé s'ancre dans la littérature sur l'éducation à l'esprit critique (Pasquinelli, 2022), qui insiste sur la nécessité de partir des représentations préexistantes des apprenants plutôt que de les contourner, et de développer des outils procéduraux explicites plutôt que de se limiter à des injonctions générales à « penser par soi-même ». Il s'inspire également des principes de la neuroéducation, en privilégiant des activités qui sollicitent l'expérience concrète avant l'abstraction conceptuelle, et en intégrant la dimension émotionnelle comme objet d'apprentissage à part entière plutôt que comme obstacle à surmonter.

Les cinq axes présentés ci-dessous sont conçus comme complémentaires et non strictement séquentiels. Ils peuvent être abordés indépendamment selon les contraintes du contexte de formation, ou articulés en un parcours progressif d'une à trois journées selon la profondeur visée.

5.2 Axe 1 - Déconstruction cognitive de l'anthropomorphisme

Le premier axe vise à rendre explicite et conscient le mécanisme d'attribution automatique d'intentionnalité décrit en Section 3.1. L'objectif n'est pas d'éradiquer l'anthropomorphisme - réaction cognitive largement automatique et difficile à

supprimer volontairement - mais d'en faire un objet de réflexion métacognitive que l'apprenant peut observer chez lui-même.

L'activité centrale consiste en un exercice systématique de désanthropomorphisation du vocabulaire : les apprenants reformulent en temps réel leurs attributions intentionnelles spontanées. « L'IA m'a compris » devient « le modèle a produit une séquence de tokens statistiquement cohérente avec mon énoncé » ; « elle pense que » devient « l'algorithme a sélectionné la suite la plus probable ». Cet exercice, pratiqué collectivement dans un premier temps, vise à créer une distance réflexive entre la réaction spontanée et sa verbalisation, rendant visible le glissement cognitif qui s'opère ordinairement de façon non consciente.

Cet axe s'appuie sur les travaux de Cardon, Cointet et Mazières (2018) pour contextualiser historiquement le lexique anthropomorphique de l'IA, montrant aux apprenants que cette terminologie est le produit de choix rhétoriques situés et non le reflet d'une réalité technique.

5.3 Axe 2 - Développement de protocoles d'interrogation critique

Le deuxième axe vise à doter les apprenants d'outils méthodologiques concrets pour réactiver leur vigilance épistémique face aux productions des LLM. Il s'agit de traduire le cadre théorique de Mercier et Sperber (2017) en procédures pratiques applicables dans les situations d'usage ordinaires.

Trois protocoles sont proposés. Le protocole adversarial consiste à demander explicitement au LLM de réfuter sa propre réponse, exposant ainsi l'arbitraire des positions qu'il adopte et leur dépendance à la formulation du prompt. La validation croisée impose de confronter systématiquement toute réponse du LLM à au moins deux sources humaines ou institutionnelles indépendantes avant de l'accepter. La stratégie du juge critique invite l'apprenant à adopter délibérément une posture contradictoire face à toute réponse qui lui convient trop facilement - précisément parce que la convergence entre la réponse du LLM et ses convictions préexistantes constitue le signal le plus fiable d'un risque de biais de confirmation.

5.4 Axe 3 - Reconnaissance des contextes de vulnérabilité

Le troisième axe cible la dimension situationnelle identifiée en Section 3.3. Il s'agit de développer chez les apprenants une métacognition sur leurs propres états émotionnels au moment de l'interaction avec un LLM, afin qu'ils puissent identifier les contextes dans lesquels leur vulnérabilité les expose davantage à l'hallucination émotionnelle.

L'activité centrale consiste en une cartographie personnelle des moments à risque : les apprenants identifient collectivement, puis individuellement, les situations dans lesquelles la tentation de déléguer un jugement émotionnel ou moral à un LLM est la plus forte. Cette cartographie est suivie d'un protocole de pause réflexive : avant toute interaction avec un LLM dans un contexte émotionnellement chargé, l'apprenant formule explicitement ce qu'il cherche réellement - une information, une validation, un réconfort - et évalue si un LLM est l'interlocuteur approprié pour ce besoin. L'enjeu éthique de cet axe est de conscientiser sans culpabiliser : l'objectif n'est pas de proscrire l'usage

émotionnel des LLM mais d'en faire un choix éclairé plutôt qu'une réaction automatique.

5.5 Axe 4 - Littératie éthique : l'arbitraire statistique révélé

Le quatrième axe cible directement la seconde manifestation de l'hallucination émotionnelle - l'arbitraire statistique - en donnant aux apprenants une expérience concrète de l'absence de fondement moral réel dans les productions des LLM.

L'activité principale consiste à soumettre un même dilemme éthique à plusieurs LLM distincts - et au même LLM formulé différemment - pour observer la variabilité des « positions morales » obtenues. Cette expérience de contradiction révèle de façon saisissante que les réponses dites morales des LLM varient selon le modèle utilisé, la langue de la requête et la formulation du prompt, démontrant qu'elles ne reflètent aucune position éthique stable mais uniquement des distributions de probabilité sur des corpus textuels. La conclusion pédagogique est formulée explicitement : un LLM peut utilement informer un jugement en exposant des arguments ou des perspectives alternatives, mais il ne peut en aucun cas le remplacer ni le valider. La responsabilité du jugement moral demeure irréductiblement celle de l'humain.

5.6 Axe 5 - Renforcement de l'autonomie cognitive

Le cinquième axe constitue le point d'aboutissement du dispositif. Après avoir déconstruit les mécanismes de l'hallucination émotionnelle et développé des outils de vigilance, il s'agit de repositionner positivement le LLM comme instrument heuristique au service d'une pensée autonome renforcée - et non comme obstacle à l'autonomie.

L'activité centrale est la dialectique augmentée : les apprenants utilisent délibérément le LLM pour générer des contre-arguments à leurs propres positions, des hypothèses alternatives à leurs analyses, des objections à leurs conclusions. Le LLM est ainsi utilisé à rebours de son usage spontané - non pour valider mais pour challenger. Cette pratique vise à développer le plaisir de la pensée contradictoire et à installer durablement une posture intellectuelle dans laquelle le LLM est un interlocuteur stimulant plutôt qu'une autorité rassurante.

Le dispositif se conclut par l'élaboration individuelle d'un contrat d'usage personnel : un document dans lequel chaque apprenant formalise explicitement les contextes dans lesquels il considère l'usage d'un LLM comme légitime et ceux dans lesquels il s'engage à privilégier d'autres ressources - humaines, documentaires ou réflexives. Ce contrat, rédigé en fin de parcours, constitue à la fois un outil pédagogique et un indicateur de progression vers l'autonomie cognitive.

5.7 Articulation et modalités de déploiement

Les cinq axes s'articulent selon une progression logique qui va de la déconstruction cognitive vers la reconstruction autonome, en passant par l'outillage procédural et la prise de conscience situationnelle. Cette progression peut être déployée dans des formats variés : une journée de formation intensive couvrant les axes 1, 2 et 3 pour un premier niveau de sensibilisation ; un parcours complet de trois journées intégrant l'ensemble des axes pour une

transformation durable des pratiques ; ou une intégration modulaire dans des cours existants d'enseignement supérieur, chaque axe pouvant constituer une séquence autonome de deux heures.

Il convient de préciser le statut épistémique de ce dispositif : il s'agit d'une proposition fondée théoriquement, dont les axes s'inscrivent dans des approches dont l'efficacité a été documentée dans des domaines adjacents - éducation aux médias et à l'information, programmes de développement de la pensée critique (Pasquinelli, 2022), interventions de littératie numérique en enseignement supérieur - mais qui n'a pas encore fait l'objet d'une évaluation empirique propre. Son test en conditions réelles, avec mesure comparative des scores aux dimensions du questionnaire avant et après intervention, constitue un prolongement direct et prioritaire de la présente recherche.

6. Conclusion et perspectives

6.1 Synthèse des apports

Ce working paper propose une contribution articulée autour de quatre dimensions complémentaires. Sur le plan terminologique, il introduit et définit le concept d'hallucination émotionnelle, absent de la littérature académique francophone comme anglophone, désignant non une défaillance du système mais une projection de l'utilisateur sur un système incapable de réciprocité réelle. Sur le plan théorique, il construit un cadre intégratif articulant trois mécanismes convergents - anthropomorphisme computationnel, défaillance de vigilance épistémique et vulnérabilité situationnelle - dont la combinaison rend compte de la diversité des manifestations observées. Sur le plan méthodologique, il présente un instrument de mesure original - questionnaire en cinq dimensions et deux vignettes situationnelles - conçu pour rendre empiriquement testables des hypothèses jusqu'ici restées au stade de l'intuition clinique ou de l'observation informelle. Sur le plan appliqué, enfin, il propose un dispositif pédagogique en cinq axes directement opérationnalisable dans des contextes de formation initiale et continue.

6.2 Limites actuelles

Plusieurs limites méritent d'être explicitement signalées. Les données empiriques étant en cours de collecte au moment de la rédaction, les hypothèses formulées restent à ce stade non confirmées : ce document a le statut d'un cadrage théorique et méthodologique, et non d'un article de résultats. La population ciblée - étudiants en formations business et marketing dans un contexte géographique limité - restreint la portée des généralisations qui pourront être formulées à partir des données. L'instrument de mesure, bien qu'ancré dans des cadres théoriques validés, n'a pas encore fait l'objet d'une validation psychométrique formelle. Enfin, l'évolution rapide des LLM - en termes de capacités, d'interfaces et de modes d'usage - impose une prudence particulière quant à la stabilité dans le temps des phénomènes décrits.

La mesure de la dissonance conscience/réaction constitue également une limite instrumentale spécifique : le nombre d'items dédiés à H2 demeure insuffisant

pour construire un indice composite robuste. Le renforcement de cette dimension représente un axe prioritaire pour les versions ultérieures de l'instrument.

6.3 Perspectives de recherche

Les résultats empiriques attendus pour le second semestre 2026 permettront de confirmer, nuancer ou invalider le modèle intégratif proposé, et d'alimenter des publications dans des revues à comité de lecture telles que *Distances et médiations des savoirs* ou *Interfaces numériques*. À plus long terme, plusieurs pistes d'extension méritent d'être mentionnées sans pouvoir être développées ici : une transposition du cadre d'analyse à d'autres populations - enseignants, formateurs, professionnels en reconversion - dont les dynamiques d'usage des LLM présentent des enjeux spécifiques en termes de modélisation pour les apprenants ; la conduite d'études longitudinales permettant de mesurer l'évolution des projections émotionnelles avec l'ancienneté d'usage ; et des comparaisons interculturelles susceptibles d'évaluer dans quelle mesure les mécanismes identifiés sont universels ou modulés par des facteurs culturels et linguistiques.

6.4 Enjeux sociétaux

Au-delà de ses implications académiques, la question posée par ce working paper s'inscrit dans un enjeu sociétal plus large. L'hallucination émotionnelle n'est pas seulement un phénomène individuel : elle représente un risque systémique pour l'autonomie cognitive collective dans des sociétés où les LLM occupent une place croissante dans la formation des opinions, la prise de décision et la régulation des émotions. Les populations les plus vulnérables - en termes d'isolement, de faible littératie numérique ou de précarité psychologique - y sont probablement exposées de façon disproportionnée, ce qui pose des questions d'équité que ni les concepteurs de LLM ni les institutions éducatives ne peuvent continuer d'ignorer. La recherche présentée ici s'inscrit dans cet effort collectif de compréhension, avec la conviction que l'éducation critique demeure le levier le plus puissant et le plus durable face aux effets non intentionnels des systèmes d'intelligence artificielle.

Références bibliographiques

Bibliographie en cours de consolidation - version enrichie à paraître.

Bender, E. M., Gebru, T., McMillan-Major, A., & Shmitchell, S. (2021). On the dangers of stochastic parrots: Can language models be too big? *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency*, 610-623. <https://doi.org/10.1145/3442188.3445922>

Cardon, D., Cointet, J.-P., & Mazières, A. (2018). La revanche des neurones : L'invention des machines inductives et la controverse de l'intelligence artificielle. *Réseaux*, 211(5), 173-220. <https://doi.org/10.3917/res.211.0173>

- Epley, N., Waytz, A., & Cacioppo, J. T. (2007). On seeing human: A three-factor theory of anthropomorphism. *Psychological Review*, 114(4), 864-886. <https://doi.org/10.1037/0033-295X.114.4.864>
- Jakesch, M., Hancock, J. T., & Naaman, M. (2023). Human heuristics for AI-generated language are flawed. *Proceedings of the National Academy of Sciences*, 120(11), Article e2208839120. <https://doi.org/10.1073/pnas.2208839120>
- Mercier, H., & Sperber, D. (2017). *The enigma of reason*. Harvard University Press.
- Nass, C., & Moon, Y. (2000). Machines and mindlessness: Social responses to computers. *Journal of Social Issues*, 56(1), 81-103. <https://doi.org/10.1111/0022-4537.00153>
- Pasquinelli, E. (2022). *Éduquer à l'esprit critique : Bases théoriques et indications pratiques pour l'enseignement et la formation*. Retz.
- Skjuve, M., Følstad, A., Fostervold, K. I., & Brandtzaeg, P. B. (2021). My chatbot companion: A study of human-chatbot relationships. *International Journal of Human-Computer Studies*, 149, Article 102601. <https://doi.org/10.1016/j.ijhcs.2021.102601>
- Turkle, S. (2011). *Alone together: Why we expect more from technology and less from each other*. Basic Books.